오픈소스 LLM-as-a-Judge의 신뢰도 분석: 평가자 크기 스케일링, 잔여 불일치의 순서 민감화, 그리고 비용 효율적 평가

박승현° (부산대학교 정보컴퓨터공학부 인공지능전공, CLINK 연구실)

Reliability Analysis of Open-Source LLM-as-a-Judge: Judge Scaling, Order-Sensitive Residual Errors, and Cost-Efficient Evaluation

Seunghyun Park° (CLINK Lab, Dept. of CSE (AI), Pusan National University)
shp09240000@pusan.ac.kr

요 약

LLM-as-a-Judge가 널리 쓰이고 있으나, 오픈소스 judge의 신뢰도를 크기 변화, 앙상블 설계, 문항 축소까지 묶어 분석한 연구는 드물다. 본 논문은 MT-Bench 프로토콜을 충실히 구현한 뒤 오픈소스 judge 신뢰도에 대한 세 가지 실증 결과를 보고한다. Qwen2.5 7B · 14B · 32B를 평가자로, 7종 오픈소스 LLM을 피평가자로 둔 main 실험에서 pairwise 불일치율은 78.75%→46.85%→32.86%로 단조 감소하였다. 반면 불일치 쌍 내 first-position 승률은 84.2%→93.5%→94.9%로 증가하여, 잔여 불일치가 더 순서 민감한 사례에 집중됨을 보였다. 또한 다수결 앙상블은 58.63%로 악화된 반면, inconsistent를 기권으로 해석한 abstain 앙상블은 불일치율을 24.70%까지 낮추고 decisive rate를 75.3%까지 높였다. 마지막으로 변별도 기반 Top-Disc-40은 동일 7개 모델 집합에서 same-set upper bound로서 전체 서열을 보존했으며, 11개 모델 풀의 330개 hold-out split에서는 세 judge 공통으로 60문항이 더 안전한 운영점으로 나타났다. 보조적으로 InternLM2.5-20B와 GPT-4o-mini는 Qwen2.5-32B와의 broad rank pattern을 각각 $\rho = 0.893, 0.964$ 수준으로 유지하였다.

1. 서론

LLM-as-a-Judge는 개방형 생성 과제의 자동 평가 대안으로 주목받고 있으나, 상용 judge의 비용과 재현성 한계로 인해 오픈소스 judge 신뢰도 분석이 중요해지고 있다. 기존 연구는 위치 편향 [2] 또는 불일치 측정 [3]에 주로 집중했으며, judge 크기 변화, 앙상블 설계, 문항 축소를 한 프레임으로 다룬 연구는 드물다.

본 논문은 MT-Bench 프로토콜을 동일하게 구현한 뒤 오픈소스 judge reliability의 핵심 병목을 분석한다. 핵심 기여는 (1) same-family judge scaling, (2) abstain 기반 앙상블 설계, (3) same-set upper bound와 repeated hold-out을 함께 사용한 tinyMT-Bench 운영점 분석이다. 구체적으로 다음 네 가지 연구 질문을 다룬다: **RQ1** 평가자 크기 변화와 불일치율의 관계, **RQ2** 불일치 감소 이후 잔여 불일치의 성격 변화 분석, **RQ3** 앙상블 설계가 신뢰도에 미치는 영향, **RQ4** 변별도 기반 문항 선택으로 비용 절감과 서열 보존의 양립 가능성.

2. 관련 연구

Zheng et al. [1]은 MT-Bench와 Chatbot Arena를 통해 GPT-4 기반 judge 프로토콜을 제안하였고, Shi et al. [2]은 위치 편향을, Park et al. [3]은 AB/BA 양방향 평가 기반 불일치율을 분석하였다. 그러나 기존 연구는 judge 크기 변화에 따른 잔여 오류의 성격 변화, 앙상블 decision rule, 최소 평가 문항 수를 함께 다루지 않았다.

3. 실험 설계

3.1 실험 환경

MT-Bench [1]의 80문항(8개 카테고리, 2턴)을 사용한다. 피평가 모델은 7종 오픈소스 chat LLM이며, main judge는 Qwen2.5-7B/14B/32B-Instruct다. 보조 교차 검증으로 동일 seen-7 집합에 대해 InternLM2.5-7B/20B와 GPT-4o-mini도 추가 실행하였다. 답변 생성은 temperature 0.7, judge는 temperature 0.0(greedy)로 고정하였다.

3.2 실험 단계

전체 실험은 6개 단계로 진행하였다. Phase 1은 self-judge 기준선, Phase 2는 외부 14B sanity check, Phase 3은 **메인 Qwen judge scaling**, Phase 4와 5는 각각 InternLM과 GPT-4o-mini를 이용한 보조 검증, Phase 6은 11개 모델 풀의 330개 hold-out split 반복 검증이다.

3.3 평가 방식 및 지표

전체 파이프라인은 (1) 80문항 2턴 답변 생성, (2) judge 추론, (3) 파싱 및 집계의 세 단계다. Single-grade는 Turn 1 단일 프롬프트와 Turn 2 multi-turn 컨텍스트를 사용하며, 각 turn의 1–10점을 파싱해 모델별 평균 점수를 계산한다. Pairwise는 동일 문항에 대해 AB/BA 두 번 평가하고, BA 판정을 원래 순서로 정규화한 뒤 두 verdict가 일치할 때만 winner를 선언한다. 불일치는 “inconsistent”로 기록한다. 주요 지표는 pairwise 불일치율, 불일치 쌍 내 first-position 승률, judge 간 Spearman ρ다.

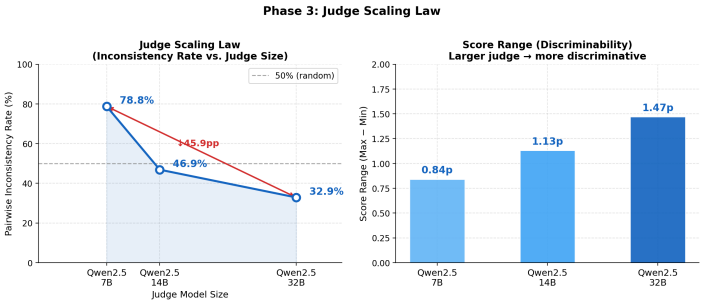

그림 1: Qwen2.5 평가자 크기별 불일치율. 크기 증가에 따른 단조 감소가 확인된다.

3.4 앙상블 설계 2종

다수결은 3개 judge의 출력을 일반 표로 집계한다. **기권**은 "inconsistent"를 low-confidence abstention으로 보고 결정적 표들만 남겨 winner를 선언한다. 예를 들어 $(inconsistent, inconsistent, A)$는 다수결에서는 inconsistent이지만, 기권 방식에서는 A로 복구된다. 핵심은 저품질 judge의 불확실한 표를 일반 vote와 동일하게 세지 않는 것이다.

4. 실험 결과

4.1 평가자 크기 비교와 불일치율 (RQ1)

그림 1과 같이 전체 불일치율은 7B(78.75%) → 14B(46.85%) → 32B(32.86%)로 단조 감소하였다. Math와 Coding이 가장 낮고, Writing과 STEM이 가장 높았다. 이는 **Qwen2.5 동일 패밀리 3개 크기에서 관찰된 empirical trend**이며, 보편적 scaling law를 주장하는 결과는 아니다. Bootstrap 95% CI는 넓지만, 7B–14B $\rho = 0.821$, 14B–32B $\rho = 0.750$으로 broad rank consistency는 유지되었다. 보조 cross-family check에서 Qwen2.5-32B와의 Spearman ρ는 InternLM2.5-20B 0.893, GPT-4o-mini 0.964였다. InternLM2.5-7B는 pairwise error rate가 72.6%로 높아 single-grade sanity check 수준으로만 해석하였다.

4.2 불일치 감소 이후 잔여 불일치의 성격 변화 (RQ2)

불일치율 감소만으로 신뢰도 향상을 단정할 수는 없다. 그림 2와 같이 first-position 승률은 7B(84.2%) → 14B(93.5%) → 32B(94.9%)로 증가하였다. 이는 위치 편향 자체의 절대 증가라기보다, 다른 유형의 오류가 줄어든 뒤 남아 있는 불일치가 order-sensitive case에 더 집중됨을 시사한다.

4.3 앙상블 평가자 설계 비교 (RQ3)

표 1과 그림 3에서 다수결 앙상블은 58.63%로 단일 32B(32.86%)보다 오히려 악화되었다. 반면 기권 방식은 24.70%까지 낮췄고, 1,680쌍 중 604쌍(36%)을 inconsistent에서 winner로 복구하였다. decisive rate도 단일 32B 67.1%, 다수결 41.4%

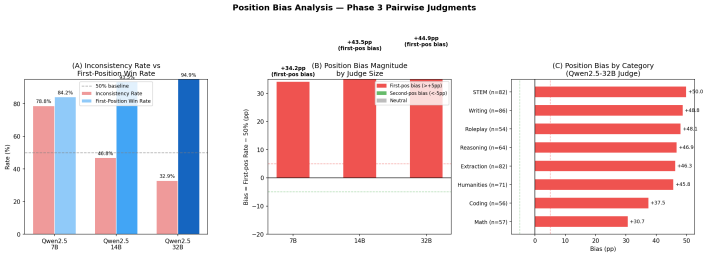

그림 2: 평가자 크기별 불일치율(좌) 및 first-position 승률(우). 불일치율은 감소하지만 first-position 승률은 증가한다.

표 1: 평가 방식별 전체 불일치율

평가 방식	불일치율
단일 7B	78.75%
단일 14B	46.85%
단일 32B	32.86%
앙상블 다수결	58.63%
앙상블 기권 (제안)	**24.70%**

보다 높은 75.3%였다. 즉 abstain은 판정을 포기하는 전략이 아니라, low-confidence vote를 집계에서 분리해 decision quality를 높이는 규칙이다. 실무적으로는 "더 많은 judge"보다 "더 좋은 집계 규칙"이 더 중요할 수 있음을 보여준다.

4.4 tinyMT-Bench: 변별도 기반 문항 최소화 (RQ4)

그림 4와 같이 TopDisc-40은 동일 7개 모델 집합에서 $\rho = 1.000$, TopDisc-25는 $\rho = 0.964$를 보여 same-set upper bound로는 매우 강하다. 그러나 이는 selection과 검증에 같은 모델 집합을 쓴 결과이므로 upper bound로 해석해야 한다. 이를 보강하기 위해 11개 모델 풀에서 dev 7, test 4의 모든 hold-out split(330개)을 반복한 결과, Top-Disc-40의 평균 Spearman ρ는 Qwen2.5-32B/InternLM2.5-20B/GPT-4o-mini에서 각각 0.968/0.922/0.959였고, 60문항에서는 0.998/0.995/0.972까지 상승하였다. Top-Disc-40이 random 평균을 이긴 split 비율도 각각 80.6%, 78.5%, 85.5%로 나타났다. 따라서 공격적인 40문항은 same-set upper bound로, 더 보수적인 운영점은 60문항으로 읽는 것이 적절하다.

5. 결론

본 논문은 오픈소스 LLM-as-a-Judge의 신뢰도를 평가자 크기 스케일링, 잔여 불일치의 순서 민감화, 앙상블 설계, 비용 효율적 평가의 네 측면에서 분석하였다. 실험 결과를 바탕으로 세 가지 실용적 가이드라인을 제안한다. 핵심 메시지는 "오픈소스 judge도 쓸 수 있다"가 아니라, judge 크기, decision rule, 문항 수를 함께 설계해야 신뢰도와 비용 사이의 균형을 얻을 수 있다는 점이다.

가이드라인 1. 현재 관찰 범위(Qwen2.5 7B/14B/32B)에서는 오픈소스 평가자 32B 이상 사용을 권장한다. 단, 크기가 커질수록 남아 있는 불일치가 순서 민감한 사례로 더 집중되므로 맹목적

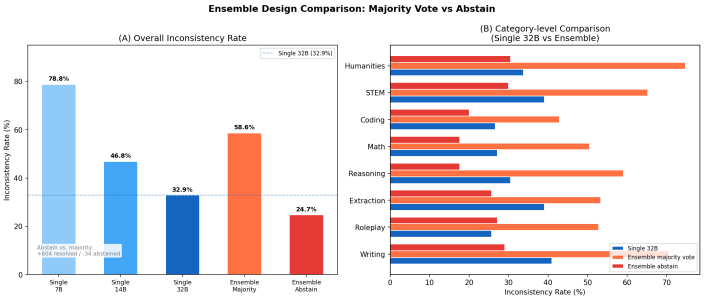

그림 3: 평가 방식별 전체 및 카테고리별 불일치율. 기권 방식은 전체와 대부분 카테고리에서 가장 낮다.

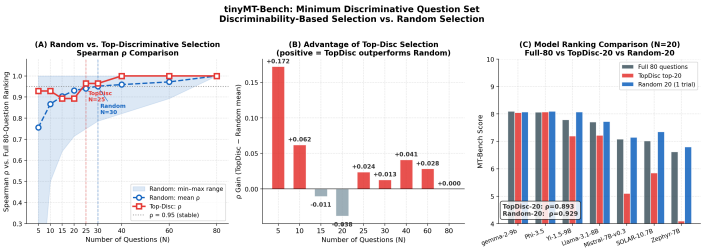

그림 4: 문항 수 N별 Spearman ρ (무작위 vs. 변별도 기반). TopDisc-40은 동일 7개 모델 집합 기준으로 80문항 기준 서열을 유지한다.

스케일링은 위험하다.

가이드라인 2. 앙상블 사용 시 다수결보다 기권 방식을 채택한다. 단일 최고 품질 평가자 대비 불일치율을 8%p 추가 절감하면서 decisive rate도 75.3%까지 높일 수 있다.

가이드라인 3. 평가 비용 절감 시 — 단, 아래 40문항 결과는 동일 7개 모델 집합의 **same-set upper bound**다 — 동일 집합 내에서는 변별도 상위 40문항 (tinyMT-Bench)으로 전체 80문항 대비 순위를 유지하면서 비용을 50% 절감할 수 있다. 반복 hold-out에서는 40문항도 강한 평균 성능을 보였지만, judge 공통으로 더 안전한 구간은 60문항이었다.

한계 및 향후 연구. 메인 scaling claim은 Qwen2.5 동일 패밀리의 3개 크기점에 한정된다. InternLM2.5-20B와 GPT-4o-mini는 보조 검증이며 full cross-family scaling study는 아니다. 또한 repeated hold-out은 strong evidence이지만, 현재 모델 풀은 같은 세대의 7B–11B급 open-weight chat 모델에 집중되어 있으므로 완전한 보편 일반화로 읽어서는 안 된다. 더 큰 규모, 다국어 환경, 독립적인 40문항-only 재실행은 후속 과제로 남는다.

참고 문헌

[1] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," *NeurIPS*, 2023.

[2] W. Shi et al., "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," *IJCNLP*, 2025. arXiv:2406.07791.

[3] Anonymous, "Are We on the Right Way to Assessing LLM-as-a-Judge?" arXiv:2512.16041, 2024.

[4] T. Vu et al., "A Survey on LLM-as-a-Judge," arXiv:2411.15594, 2024.