오픈소스 LLM-as-a-Judge의 신뢰도 분석: 판사 크기 스케일링, 위치 편향 집중, 그리고 비용 효율적 평가

박승현° (부산대학교 정보컴퓨터공학부 인공지능전공, CLINK 연구실)

Reliability Analysis of Open-Source LLM-as-a-Judge: Judge Size Scaling, Position Bias Concentration, and Cost-Efficient Evaluation

Seunghyun Park° (CLINK Lab, Dept. of CSE (AI), Pusan National University)
shp09240000@pusan.ac.kr

요 약

대형 언어 모델(LLM)을 평가자로 활용하는 LLM-as-a-Judge 방식이 확산되고 있으나, 기존 연구는 위치 편향 또는 불일치율 측정에 집중해 왔으며 judge 크기 변화, 앙상블 설계, 문항 축소 효과를 통합적으로 분석한 연구는 드물다. 본 논문은 MT-Bench 80문항을 기반으로 Qwen2.5 계열 7B · 14B · 32B를 평가자로, 7종의 오픈소스 LLM을 피평가자로 설정하여 신뢰도를 다각도로 분석한다. 실험 결과, 평가자 크기 증가에 따라 pairwise 불일치율은 단조 감소(78.75%→46.85%→32.86%)하나, 불일치 쌍 내 first-position 승률은 84.2%→93.5%→94.9%로 증가하여 남아 있는 불일치에서 위치 편향의 상대적 기여도가 커짐을 확인하였다. 또한 다수결 앙상블은 단일 고품질 평가자보다 성능이 저하되며, inconsistent 판정을 기권으로 처리하는 개선 앙상블이 이를 해결함을 실증하였다. 아울러 변별도 기반 40문항(tinyMT-Bench)은 동일 7개 모델 집합 내에서 전체 순위를 보존하면서 평가 비용을 50% 절감하였다.

1. 서론

LLM의 성능 평가는 모델 개발과 선택에 있어 핵심 과제이다. 인간 평가는 비용과 확장성 문제가 있으며, 객관식 벤치마크는 개방형 태스크를 충분히 평가하기 어렵다. 이러한 배경에서 LLM 자체를 평가자로 활용하는 LLM-as-a-Judge 방식이 주목받고 있다 [1].

상용 API의 비용 및 접근성 제약으로 인해 오픈소스 평가자 활용 수요가 증가하고 있다. 기존 연구는 위치 편향 [2] 또는 불일치 측정 [3]에 집중하였으나, 평가자 크기 변화에 따른 불일치 특성, 앙상블 설계의 효과, 최소 문항 수를 통합 분석한 연구는 부족하다.

본 논문은 다음 네 가지 연구 질문을 다룬다: **RQ1** 평가자 크기 스케일링과 불일치율의 관계, **RQ2** 불일치의 원인 및 위치 편향의 상대적 기여도 변화 분석, **RQ3** 앙상블 설계가 신뢰도에 미치는 영향, **RQ4** 변별도 기반 문항 선택으로 비용 절감과 서열 보존의 양립 가능성.

2. 관련 연구

LLM-as-a-Judge. Zheng et al. [1]은 MT-Bench와 Chatbot Arena를 통해 GPT-4 기반 평가 방식을 제안하였으며, 인간 평가자와 80% 이상의 일치율을 보고하였다.

신뢰도 분석. Shi et al. [2]은 15개 LLM 평가자를 대상으로 위치 편향을 정량화하였다. Park et al. [3]은 AB/BA 양방향 평가를 통해 불일치율이 25.3%–76.2% 범위임을 보고하였다. 그러나 이들 연구는 평가자 크기 증가에 따른 불일치에서 위치 편향의 상대적 기여도 변화, 앙상블 설계의 효과, 최소 평가 문항 수를 분석하지 않았다.

3. 실험 설계

3.1 실험 환경

MT-Bench [1]의 80문항(8개 카테고리 × 10문항, 2턴)을 사용한다. 피평가 모델은 7종: Llama-3.1-8B-Instruct, SOLAR-10.7B-Instruct, Gemma-2-9B-it, Yi-1.5-9B-Chat, Zephyr-7B-beta, Mistral-7B-Instruct-v0.3, Phi-3.5-mini-Instruct. 평가자는 Qwen2.5-7B/14B/32B-Instruct를 사용하였으며, vLLM 서버 기반으로 실행하였다. 답변 생성 temperature=0.7, 평가 temperature=0.0(greedy).

3.2 평가 방식 및 지표

Single-grade: 1–10점 채점, Turn $1 \cdot 2$ 평균을 모델 점수로 사용.

Pairwise (conservative verdict) [1]: AB · BA 양방향 비교. 두 판정이 일치할 때만 winner 선언, 불일치 시 “inconsistent” 처리.

주요 지표: (1) **불일치율**: AB/BA 판정이 다른 쌍의 비율 ($\binom{7}{2} \times 80 = 1{,}680$쌍), (2) **First-position 승률**: 불일치 쌍 중 첫 번째 제시 모델 승리 비율, (3) **Spearman** ρ: 두 평가자 간 모델 서열 순위 상관계수.

3.3 앙상블 설계 2종

다수결: inconsistent를 표로 취급, 2/3 이상 일치 시 winner.

기권: inconsistent를 기권으로 처리. 결정적 표(A 또는 B)가 존재하고 충돌하지 않을 때만 winner 선언.

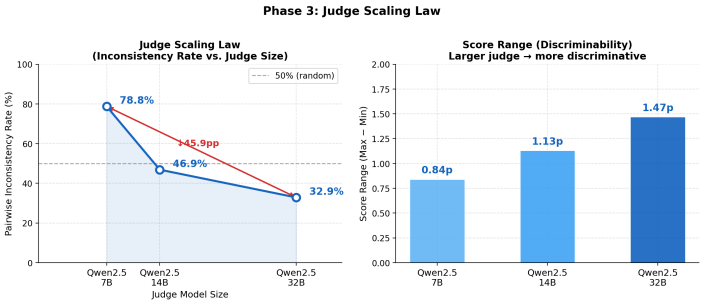

그림 1: Qwen2.5 평가자 크기별 불일치율. 크기 증가에 따른 단조 감소가 확인된다.

그림 2: 평가자 크기별 불일치율(좌) 및 first-position 승률(우). 불일치율은 감소하지만 first-position 승률은 증가한다.

4. 실험 결과

4.1 평가자 크기 스케일링과 불일치율 (RQ1)

그림 1은 평가자 크기별 불일치율을 보여준다. 전체 불일치율은 7B(78.75%) → 14B(46.85%) → 32B(32.86%)로 단조 감소하였다. Math(27.14%)와 Coding(26.67%)이 가장 낮고, Writing(40.95%)과 STEM(39.05%)이 가장 높았다. 정오 기준이 명확한 카테고리일수록 평가자가 일관된 판정을 내린다.

Cross-judge Spearman ρ (Bootstrap 95% CI, $n = 10{,}000$): 7B–14B $\rho = 0.821$ [0.643, 0.964], 14B–32B $\rho = 0.750$ [0.607, 0.964]. 평가자 크기가 달라도 모델 서열 판단은 유사하게 나타났다.

4.2 불일치 감소와 위치 편향의 상대적 기여도 증가 (RQ2)

불일치율 감소만으로 신뢰도 향상을 단정할 수 없다. 그림 2에서 확인할 수 있듯, first-position 승률은 7B(84.2%) → 14B(93.5%) → 32B(94.9%)로 평가자 크기가 커질수록 오히려 증가하였다.

이는 7B에서도 위치 편향이 이미 상당히 존재하지만, 32B에서는 남아 있는 불일치의 대부분이 위치 편향과 연결됨을 시사한다. **평가자 크기 증가는 불일치율을 낮추지만, 남아 있는 불일치에서 위치 편향의 상대적 기여도는 오히려 커진다.** Math(32B 기준 80.7%)가 가장 낮은 first-position 승률을 보인 것은 명확한 정오 기준이 위치 편향을 부분적으로 억제하기 때문이다.

표 1: 평가 방식별 전체 불일치율

평가 방식	불일치율
단일 7B	78.75%
단일 14B	46.85%
단일 32B	32.86%
앙상블 다수결	58.63%
앙상블 기권 (제안)	**24.70%**

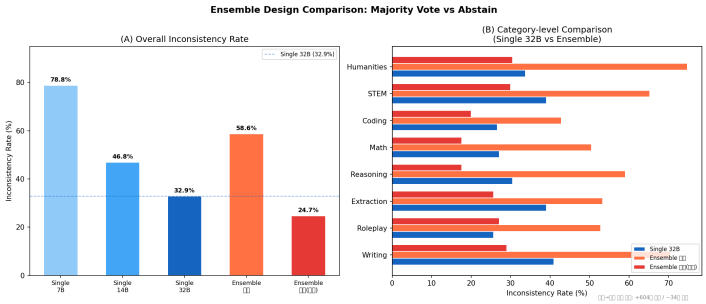

그림 3: 평가 방식별 전체 및 카테고리별 불일치율. 기권 방식은 전체와 대부분 카테고리에서 가장 낮다.

4.3 앙상블 평가자 설계 비교 (RQ3)

표 1과 그림 3은 평가 방식별 전체 및 카테고리별 불일치율을 보여준다. 다수결 앙상블(58.63%)은 단일 32B(32.86%)보다 오히려 악화되었다. 7B의 높은 inconsistency율(78.75%)로 인해 “inconsistent” 표가 다수를 차지하며 앙상블을 오염시키기 때문이다.

기권 방식(24.70%)은 단일 32B보다 낮은 불일치율을 달성하였다. 1,680쌍 중 604쌍(36%)이 inconsistent에서 winner로 전환되었다. 기권 방식은 저품질 평가자의 불확실한 판정을 집계에서 제외하여 앙상블 신뢰도를 높인다.

4.4 tinyMT-Bench: 변별도 기반 문항 최소화 (RQ4)

그림 4는 문항 수 N별 Spearman ρ를 보여준다. 무작위 선택은 평균 기준 약 30문항에서 $\rho = 0.951$로 $\rho \geq 0.95$에 도달한다. 그러나 10문항에서는 최솟값 $\rho = 0.50$으로 여전히 불안정하며, 60문항에서도 최솟값은 $\rho = 0.893$에 머물러 worst-case 기준의 $\rho \geq 0.95$를 보장하지는 못한다. 변별도(모델 간 점수 표준편차) 상위 N개를 선택하는 TopDisc-N 방식은 TopDisc-40에서 $\rho = 1.000$을 달성하여 동일 7개 모델 집합 내 서열을 보존하면서 평가 비용을 50% 절감하였다. TopDisc-25는 $\rho = 0.964$를 달성하여 69% 절감이 가능하다. 단, 선택 기준과 검증 대상이 동일 모델 집합이므로 selection bias가 존재하며, $N = 7$에서 $\rho = 1.000$과 $\rho = 0.964$의 차이는 1개 순위 역전에 해당한다.

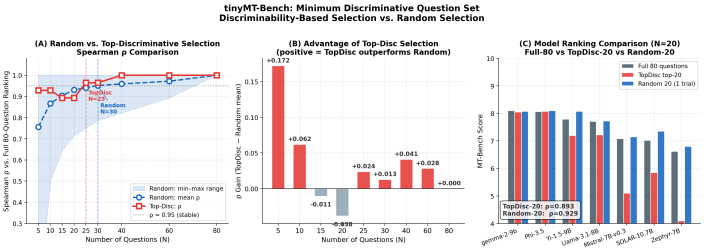

그림 4: 문항 수 N별 Spearman ρ (무작위 vs. 변별도 기반). TopDisc-40은 동일 7개 모델 집합 기준으로 80문항 기준 서열을 유지한다.

5. 결론

본 논문은 오픈소스 LLM-as-a-Judge의 신뢰도를 판사 크기 스케일링, 위치 편향, 앙상블 설계, 비용 효율적 평가의 네 측면에서 분석하였다. 실험 결과를 바탕으로 세 가지 실용적 가이드라인을 제안한다.

가이드라인 1. 오픈소스 평가자는 32B 이상 사용을 권장한다. 단, 크기가 커질수록 불일치 원인이 위치 편향으로 집중되므로 맹목적 스케일링은 위험하다.

가이드라인 2. 앙상블 사용 시 다수결보다 기권 방식을 채택한다. 단일 최고 품질 평가자 대비 불일치율을 8%p 추가 절감할 수 있다.

가이드라인 3. 평가 비용 절감 시 동일 7개 모델 집합 내에서는 변별도 상위 40문항 (tinyMT-Bench)을 사용하여 전체 80문항 대비 순위를 유지하면서 비용을 50% 절감할 수 있다.

한계 및 향후 연구. 본 연구는 단일 judge 패밀리(Qwen2.5)와 7개 피평가 모델의 한계가 있다. 또한 tinyMT-Bench는 동일 모델 집합 내 검증 결과이며, 외부 모델 및 다국어 환경에 대한 일반화는 후속 과제로 남는다.

참고 문헌

[1] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," *NeurIPS*, 2023.

[2] W. Shi et al., "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," *IJCNLP*, 2025. arXiv:2406.07791.

[3] Anonymous, "Are We on the Right Way to Assessing LLM-as-a-Judge?" arXiv:2512.16041, 2024.

[4] T. Vu et al., "A Survey on LLM-as-a-Judge," arXiv:2411.15594, 2024.