오픈소스 LLM-as-a-Judge의 신뢰도 분석: 동일 패밀리 판사 스케일링, 잔여 위치 편향, 그리고 비용 효율적 평가

박승현° (부산대학교 정보컴퓨터공학부 인공지능전공, CLINK 연구실)

Reliability Analysis of Open-Source LLM-as-a-Judge: Within-Family Judge Scaling, Residual Position Bias, and Cost-Efficient Evaluation

Seunghyun Park° (CLINK Lab, Dept. of CSE (AI), Pusan National University)
shp09240000@pusan.ac.kr

요 약

대형 언어 모델(LLM)을 평가자로 활용하는 LLM-as-a-Judge 방식이 확산되고 있으나, 기존 연구는 위치 편향 또는 불일치율 측정에 집중해 왔으며 judge 크기 변화, 앙상블 설계, 문항 축소 효과를 통합적으로 분석한 연구는 드물다. 본 논문은 MT-Bench 프로토콜을 동일하게 구현한 뒤, 그 위에서 **오픈소스 judge 신뢰도에 대한 세 가지 실증적 발견**을 제시한다. Qwen2.5 계열 7B · 14B · 32B를 평가자로, 7종의 오픈소스 LLM을 피평가자로 설정한 결과, **Qwen2.5 동일 패밀리의 3개 크기점에서** 평가자 크기 증가에 따라 pairwise 불일치율은 단조 감소(78.75%→46.85%→32.86%)하였다. 그러나 불일치 쌍 내 first-position 승률은 84.2%→93.5%→94.9%로 증가하여, 다른 원인의 불일치가 줄어든 뒤 **남아 있는 불일치에서 위치 편향 유래 사례의 상대적 비중이 커짐**을 확인하였다. 또한 다수결 앙상블은 단일 고품질 평가자보다 성능이 저하되며, inconsistent 판정을 기권으로 처리하는 개선 앙상블은 불일치율을 24.70%로 낮추면서 decisive rate도 75.3%까지 높였다. 아울러 변별도 기반 40문항(tinyMT-Bench)은 동일 7개 모델 집합 내 **same-set upper bound**로서 전체 순위를 보존하면서 평가 비용을 50% 절감하였다. 보조적으로 InternLM2.5-20B와 GPT-4o-mini에서도 Qwen2.5-32B 기준 모델 서열의 **broad rank pattern**이 Spearman $\rho = 0.893$, 0.964 수준으로 유지되어 main result의 cross-family / external 타당성을 보강하였다. 추가로 11개 모델 풀에서 **330개 hold-out split**을 반복한 결과, Top-Disc-40의 평균 Spearman ρ는 Qwen2.5-32B/InternLM2.5-20B/GPT-4o-mini에서 각각 0.968/0.922/0.959였고, 60문항에서는 0.998/0.995/0.972까지 상승하였다. 이 결과는 주로 같은 세대의 7B–11B open-weight chat 모델 범위에서 해석해야 한다.

1. 서론

LLM의 성능 평가는 모델 개발과 선택에 있어 핵심 과제이다. 인간 평가는 비용과 확장성 문제가 있으며, 객관식 벤치마크는 개방형 태스크를 충분히 평가하기 어렵다. 이러한 배경에서 LLM 자체를 평가자로 활용하는 LLM-as-a-Judge 방식이 주목받고 있다 [1].

상용 API의 비용 및 접근성 제약으로 인해 오픈소스 평가자 활용 수요가 증가하고 있다. 기존 연구는 위치 편향 [2] 또는 불일치 측정 [3]에 집중하였으나, 평가자 크기 변화에 따른 불일치 특성, 앙상블 설계의 효과, 최소 문항 수를 통합 분석한 연구는 부족하다.

본 논문은 MT-Bench 프로토콜을 동일하게 구현한 뒤, 그 위에서 judge reliability의 핵심 병목을 분석한다. 재현 자체보다 중요한 기여는 세 가지다. 첫째, Qwen2.5 동일 패밀리 내 judge scaling에서 불일치율 감소와 잔여 불일치의 순서 민감화가 동시에 나타남을 보인다. 둘째, 다수결 대신 inconsistent를 기권으로 처리하는 앙상블 설계가 더 낮은 불일치율과 더 높은 decisive rate를 제공함을 보인다. 셋째, same-set upper bound와 repeated hold-out을 함께 사용해 비용 절감형 subset의 실용적 안전 구간을 제시한다. 구체적으로 다음 네 가지 연구 질문을 다룬다: **RQ1** 평가자 크기 변화와 불일치율의 관계, **RQ2** 불일치 감소 이후 잔여 불일치의 성격 변화 분석, **RQ3** 앙상블 설계가 신뢰도에 미치는 영향, **RQ4** 변별도 기반 문항 선택으로 비용 절감과 서열 보존의 양립 가능성.

2. 관련 연구

LLM-as-a-Judge. Zheng et al. [1]은 MT-Bench와 Chatbot Arena를 통해 GPT-4 기반 평가 방식을 제안하였으며, 인간 평가자와 80% 이상의 일치율을 보고하였다.

신뢰도 분석. Shi et al. [2]은 15개 LLM 평가자를 대상으로 위치 편향을 정량화하였다. Park et al. [3]은 AB/BA 양방향 평가를 통해 불일치율이 25.3%–76.2% 범위임을 보고하였다. 그러나 이들 연구는 평가자 크기 증가에 따른 불일치에서 위치 편향의 상대적 기여도 변화, 앙상블 설계의 효과, 최소 평가 문항 수를 분석하지 않았다.

3. 실험 설계

3.1 실험 환경

MT-Bench [1]의 80문항(8개 카테고리 × 10문항, 2턴)을 사용한다. 피평가 모델은 7종: Llama-3.1-8B-Instruct, SOLAR-10.7B-Instruct, Gemma-2-9B-it, Yi-1.5-9B-Chat, Zephyr-7B-beta, Mistral-7B-Instruct-v0.3, Phi-3.5-mini-Instruct. 평가자는 Qwen2.5-7B/14B/32B-Instruct를 사용하였으며, 보조 교차 검증으로 동일 seen-7 집합에 대해 InternLM2.5-7B/20B와 GPT-4o-mini 평가자도 추가 실행하였다. vLLM 서버 기반으로 실행하였

다. 답변 생성 temperature=0.7, 평가 temperature=0.0(greedy).

3.2 평가 방식 및 지표

Single-grade: 1–10점 채점, Turn 1 · 2 평균을 모델 점수로 사용.

Pairwise (conservative verdict) [1]: AB · BA 양방향 비교. 두 판정이 일치할 때만 winner 선언, 불일치 시 "inconsistent" 처리.

주요 지표: (1) **불일치율**: AB/BA 판정이 다른 쌍의 비율 ($\binom{7}{2} \times 80 = 1{,}680$쌍), (2) **First-position 승률**: 불일치 쌍 중 첫 번째 제시 모델 승리 비율, (3) **Spearman** ρ: 두 평가자 간 모델 서열 순위 상관계수.

3.3 앙상블 설계 2종

다수결: inconsistent를 하나의 표로 취급, 2/3 이상 일치 시 winner.

기권: inconsistent를 기권으로 처리. 결정적 표(A 또는 B)가 존재하고 충돌하지 않을 때만 winner 선언. 저품질 judge의 불확실한 verdict를 일반 투표와 동일하게 집계하면 노이즈가 다수결을 오염시킬 수 있다. 본 연구의 기권 방식은 이러한 low-quality vote를 보수적으로 제외해, 판정 수는 유지하면서 decision quality를 보존하려는 설계다.

4. 실험 결과

4.1 평가자 크기 비교와 불일치율 (RQ1)

그림 1은 평가자 크기별 불일치율을 보여준다. 전체 불일치율은 7B(78.75%) → 14B(46.85%) → 32B(32.86%)로 단조 감소하였다. Math(27.14%)와 Coding(26.67%)이 가장 낮고, Writing(40.95%)과 STEM(39.05%)이 가장 높았다. 정오 기준이 명확한 카테고리일수록 평가자가 일관된 판정을 내린다. 다만 이는 **Qwen2.5 동일 패밀리 3개 크기에서 관찰된 empirical trend**이며, 일반적인 scaling law를 주장하는 결과는 아니다.

Cross-judge Spearman ρ (Bootstrap 95% CI, $n = 10{,}000$): 7B–14B $\rho = 0.821$ [0.643, 0.964], 14B–32B $\rho = 0.750$ [0.607, 0.964]. 표본 수가 7개 모델뿐이라 CI는 넓지만, 상위권/하위권 블록을 구분하는 **broad rank consistency**는 유지되었다. 보조 cross-family check에서 Qwen2.5-32B와의 Spearman ρ는 InternLM2.5-20B에서 0.893, GPT-4o-mini에서 0.964였다. 반면 InternLM2.5-7B의 pairwise 단계는 verdict format을 안정적으로 따르지 못해 1,680개 중 1,220개(72.6%)가 error로 남았고, single-grade sanity check 수준으로만 해석하였다.

4.2 불일치 감소 이후 잔여 불일치의 성격 변화 (RQ2)

불일치율 감소만으로 신뢰도 향상을 단정할 수 없다. 그림 2에서 확인할 수 있듯, first-position 승률은 7B(84.2%) → 14B(93.5%) → 32B(94.9%)로 평가자 크기가 커질수록 오히려 증가하였다.

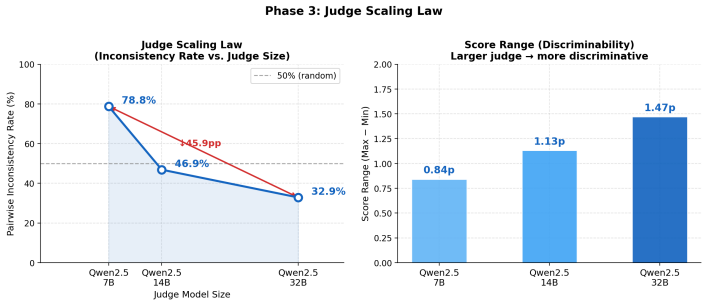

그림 1: Qwen2.5 평가자 크기별 불일치율. 크기 증가에 따른 단조 감소가 확인된다.

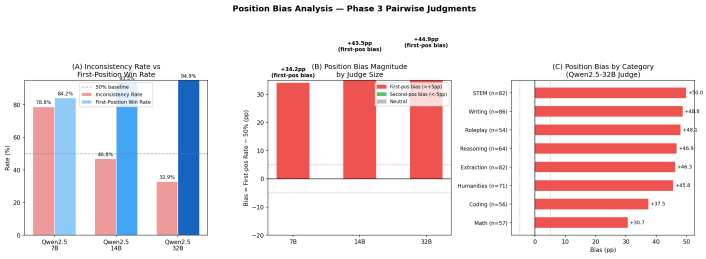

그림 2: 평가자 크기별 불일치율(좌) 및 first-position 승률(우). 불일치율은 감소하지만 first-position 승률은 증가한다.

이는 7B에서도 위치 편향이 이미 상당히 존재하지만, 32B에서는 위치와 무관한 다른 유형의 불일치가 더 많이 제거된 뒤 남아 있는 사례가 순서 민감한 쌍에 더 집중됨을 시사한다. 따라서 본 결과는 **위치 편향 자체의 절대적 증가**보다 **잔여 불일치의 성격이 order-sensitive case 중심으로 이동했다**는 방향으로 해석하는 것이 안전하다. Math(32B 기준 80.7%)가 가장 낮은 first-position 승률을 보인 것은 명확한 정오 기준이 위치 편향을 부분적으로 억제하기 때문이다.

4.3 앙상블 평가자 설계 비교 (RQ3)

표 1과 그림 3은 평가 방식별 전체 및 카테고리별 불일치율을 보여준다. 다수결 앙상블(58.63%)은 단일 32B(32.86%)보다 오히려 악화되었다. 7B의 높은 inconsistency율(78.75%)로 인해 "inconsistent" 표가 다수를 차지하며 앙상블을 오염시키기 때문이다.

기권 방식(24.70%)은 단일 32B보다 낮은 불일치율을 달성하였다. 1,680쌍 중 604쌍(36%)이 inconsistent에서 winner로 전환되었다. 또한 decisive rate는 단일 32B 67.1%, 다수결 41.4%보다 높은 75.3%였다. 기권 방식은 저품질 평가자의 불확실한 판정을 집계에서 제외하여 앙상블 신뢰도를 높이며, 단순한 판정 회피 전략이 아님을 보여준다.

표 1: 평가 방식별 전체 불일치율

평가 방식	불일치율
단일 7B	78.75%
단일 14B	46.85%
단일 32B	32.86%
앙상블 다수결	58.63%
앙상블 기권 (제안)	**24.70%**

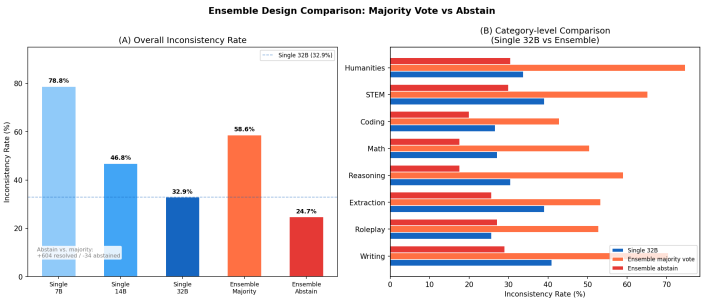

그림 3: 평가 방식별 전체 및 카테고리별 불일치율. 기권 방식은 전체와 대부분 카테고리에서 가장 낮다.

4.4 tinyMT-Bench: 변별도 기반 문항 최소화 (RQ4)

그림 4는 문항 수 N별 Spearman ρ를 보여준다. 무작위 선택은 평균 기준 약 30문항에서 $\rho = 0.951$로 $\rho \geq 0.95$에 도달한다. 그러나 10문항에서는 최솟값 $\rho = 0.50$으로 여전히 불안정하며, 60문항에서도 최솟값은 $\rho = 0.893$에 머물러 worst-case 기준의 $\rho \geq 0.95$를 보장하지는 못한다. 변별도(모델 간 점수 표준편차) 상위 N개를 선택하는 TopDisc-N 방식은 TopDisc-40에서 $\rho = 1.000$을 달성하여 동일 7개 모델 집합 내 서열을 보존하면서 평가 비용을 50% 절감하였다. TopDisc-25는 $\rho = 0.964$를 달성하여 69% 절감이 가능하다. 단, 선택 기준과 검증 대상이 동일 모델 집합이므로 selection bias가 존재한다. 따라서 same-set 결과는 비용 절감형 subset construction의 **upper bound**로 해석해야 한다. 이를 보강하기 위해 11개 모델 풀에서 dev 7, test 4의 모든 hold-out split(330개)을 반복한 결과, Top-Disc-40의 평균 Spearman ρ는 Qwen2.5-32B/InternLM2.5-20B/GPT-4o-mini에서 각각 0.968/0.922/0.959였고, random 평균 0.941/0.847/0.880보다 높았다. Top-Disc-40이 random 평균을 이긴 split 비율도 각각 80.6%, 78.5%, 85.5%로 나타났다. 60문항에서는 평균 ρ가 0.998/0.995/0.972까지 상승하여 더 보수적인 안전 구간으로 해석할 수 있었다. 다만 split들이 서로 모델을 공유하므로 완전 독립 표본은 아니며, random 95% 구간도 일부 N에서 1.0까지 도달해 deterministic superiority를 주장할 수는 없다. 또한 selection에 사용한 Qwen2.5-32B와 같은 judge를 test에도 적용한 결과는 부분적으로 순환적이므로, 더 독립적인 외부 증거는 InternLM2.5-20B와 GPT-4o-mini 쪽이다. $N = 7$에서 $\rho = 1.000$과 $\rho = 0.964$의 차이는 1개 순위 역전에 해당한다.

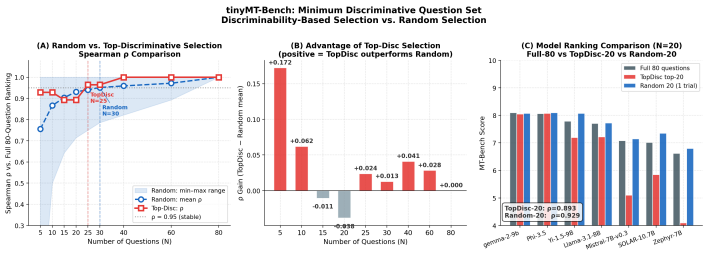

그림 4: 문항 수 N별 Spearman ρ (무작위 vs. 변별도 기반). TopDisc-40은 동일 7개 모델 집합 기준으로 80문항 기준 서열을 유지한다.

5. 결론

본 논문은 오픈소스 LLM-as-a-Judge의 신뢰도를 판사 크기 스케일링, 위치 편향, 앙상블 설계, 비용 효율적 평가의 네 측면에서 분석하였다. 실험 결과를 바탕으로 세 가지 실용적 가이드라인을 제안한다.

가이드라인 1. 현재 관찰 범위(Qwen2.5 7B/14B/32B)에서는 오픈소스 평가자 32B 이상 사용을 권장한다. 단, 크기가 커질수록 남아 있는 불일치에서 위치 편향 유래 사례의 비중이 커지므로 맹목적 스케일링은 위험하다.

가이드라인 2. 앙상블 사용 시 다수결보다 기권 방식을 채택한다. 단일 최고 품질 평가자 대비 불일치율을 8%p 추가 절감하면서 decisive rate도 75.3%까지 높일 수 있다.

가이드라인 3. 평가 비용 절감 시 동일 7개 모델 집합 내에서는 변별도 상위 40문항 (tinyMT-Bench)을 사용하여 전체 80문항 대비 순위를 유지하면서 비용을 50% 절감할 수 있다. 반복 hold-out에서는 40문항도 강한 평균 성능을 보였지만, judge 공통으로 더 안전한 구간은 60문항이었다.

한계 및 향후 연구. 메인 scaling claim은 단일 judge 패밀리(Qwen2.5)에 한정된다. 보조적으로 InternLM2.5-7B/20B와 GPT-4o-mini를 추가했지만, 이는 seen-7 집합에 대한 cross-family sanity check이지 full cross-family scaling study는 아니다. 특히 InternLM2.5-7B의 pairwise 단계는 높은 error rate(72.6%)를 보여 pairwise 신뢰도 비교에는 부적합했다. 또한 본 연구는 7개 피평가 모델의 한계가 있다. tinyMT-Bench는 same-set 결과와 330 split hold-out 결과를 모두 확보했지만, split들이 서로 모델을 공유해 상관이 있고 random 95% 구간도 일부 N에서 1.0까지 도달한다. 또한 현재 모델 풀은 같은 세대의 7B–11B급 open-weight chat 모델에 집중되어 있다. 따라서 repeated hold-out 결과 역시 이 범위의 강한 경험적 경향으로 해석해야 하며, 완전한 보편 일반화로 읽어서는 안 된다. 외부 모델, 다국어 환경, 독립적인 40문항-only 재실행은 후속 과제로 남는다.

참고 문헌

[1] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," *NeurIPS*, 2023.

[2] W. Shi et al., "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," *IJCNLP*, 2025. arXiv:2406.07791.

[3] Anonymous, "Are We on the Right Way to Assessing LLM-as-a-Judge?" arXiv:2512.16041, 2024.

[4] T. Vu et al., "A Survey on LLM-as-a-Judge," arXiv:2411.15594, 2024.