오픈소스 LLM-as-a-Judge의 신뢰도 분석

MT-Bench base paper study + reproduction + repo walkthrough

랩미팅 겸 논문스터디 발표
베이스 논문을 먼저 이해하고, 그 위에 제가 재현·확장한 부분을 단계별로 설명합니다.

메인 jud
Qwen 7B/14B/32B

보조 jud
InternLM2 0B · GPT-4o-mini

Hold-ou
330 splits × 200 random draws

오늘 발표에서 답할 질문

- 베이스 논문은 무엇을 제안했고 왜 중요했는가?
- 내 재현 코드는 어디까지 원문을 따라갔고 어디서 확장했는가?
- 오픈소스 judge를 실제로 믿어도 되는가?
- 비용을 줄이면서도 순위를 얼마나 보존할 수 있는가?

박승현
CLINK Lab, Pusan National University

오늘 발표의 큰 흐름

이 슬라이드의 목적: 20분 동안 무엇을 어떤 순서로 듣게 되는지 먼저 안정적으로 안내한다.

- 1부: 베이스 논문이 해결하려는 문제와 핵심 기여
- 2부: 내 재현 파이프라인과 Phase 1-6 실험 구조
- 3부: 메인 결과, Git 정리 방식, 그리고 최종 해석

베이스 논문이 해결하려던 문제

이 슬라이드의 목적: MT-Bench 논문이 기존 평가 패러다임의 어떤 공백을 찔렀는지 이해시킨다.

- 기존 객관식 벤치마크는 open-ended, multi-turn 선호를 충분히 반영하지 못함
- 사람 선호를 직접 모으는 평가는 느리고 비싸서 반복 실험이 어려움
- 강한 LLM을 judge로 쓰면 인간 선호를 빠르게 근사할 수 있는가가 핵심 질문

Base paper question: “Can a strong LLM approximate human preference at scale?”

베이스 논문의 핵심 자산: MT-Bench와 Chatbot

이 슬라이드의 목적: 원 논문이 어떤 benchmark와 human evidence를 만들었는지 구조적으로 설명한다.

- MT-Bench: 8개 카테고리 × 10문항 = 80개 multi-turn 질문
- Chatbot Arena: 익명 대결 플랫폼으로 실제 사용자 선호를 대규모 수집
- 공개 자산: 80문항, 3K expert votes, 30K conversations with human preferences

베이스 논문의 judge 프로토콜과 주요 결론

이 슬라이드의 목적: 원 논문을 자세히 설명하되, 우리가 재현할 프로토콜이 무엇인지 분명히 한다.

- GPT-4 judge는 position, verbosity, self-enhancement bias 가능성을 함께 분석
- bias 완화 후 GPT-4 judge는 human preference와 80%+ 수준으로 일치
- 결론: LLM-as-a-Judge는 scalable하고 explainable한 human preference 근사 도구

베이스 논문에서 무엇을 그대로 가져오고, 무엇을 바꿨

이 슬라이드의 목적: 원 논문의 설계와 내 재현/확장 사이의 대응 관계를 명확히 연결한다.

- 그대로 가져온 것: 80문항 MT-Bench, single/pairwise/reference 3종 채점 구조
- 바꾼 것: GPT-4 judge를 Qwen·InternLM·GPT-4o-mini로 대체하고 raw artifact를 전부 저장
- 확장한 것: judge scaling, residual bias, ensemble, tinyMT-Bench, exhaustive hold-out

이 발표는 '원 논문을 흉내 낸 실험'이 아니라, '원 논문의 프로토콜을 재현 가능한 오픈소스 파이프라인으로 옮긴 작업'입니다.

재현
프로토콜

대체
오픈 judge

확장
Phase 3-6

산출물
raw→paper

그렇다면 내가 재현에서 던진 질문은 무엇인가

이 슬라이드의 목적: 원 논문의 공헌과 한계를 바탕으로 내 연구 질문이 어디서 생겼는지 연결한다.

- 원 논문은 강한 closed-source judge 중심, 오픈소스 judge 신뢰도는 미해결
- judge 크기 변화, residual bias, ensemble, 문항 축소는 충분히 통합 분석되지 않음
- 따라서 재현 + 확장 질문 4개(RQ1-RQ4)를 새로 세움

내 Git 저장소는 무엇을 재현 가능하게 만들었나

이 슬라이드의 목적: 코드베이스가 단순 결과 저장소가 아니라 재현 가능한 연구 파이프라인이라는 점을 보여준다.

Repo 핵심 구조

- `src/mtbench_repro/` — judge client, prompts, aggregation, CLI
- `scripts/` — generation, judge 실행, phase 분석, 발표용 재집계
- `data/` — answer/judgment/raw csv/result summary
- `figures/` — 논문 및 발표에 바로 쓰는 핵심 그림
- `paper/` — KCC 원고, blind 버전, PDF

실행 흐름

- 1. 답변 생성
- 2. single / pairwise / reference judge
- 3. aggregate 및 csv 생성
- 4. figure 생성
- 5. README / paper 동기화

재현성 포인트

- Phase별 raw judgment와 summary csv를 분리
- mock / real 결과 분리 및 reference 별도 집계
- PowerPoint용 figure까지 repo에서 다시 생성 가능
- 최종 발표 자료도 script 기반으로 생성

Git에서 실제로 어디를 보면 무엇이 보이는가

이 슬라이드의 목적: 랩미팅 이후에도 저장소를 읽을 수 있도록 산출물 탐색 경로를 구체적으로 알려준다.

- `README.md`는 전체 서사, `data/`는 raw judgment와 요약 CSV, `figures/`는 발표/논문 그림
- `paper/`에는 blind/non-blind 원고와 PDF, `presentation/`에는 오늘 발표자료와 대본
- 질문이 생기면 '결론 → figure → csv → raw jsonl' 순서로 역추적하면 됨

교수님이 저장소를 훑으실 때는 README만 보지 말고, 결과 figure 옆의 CSV와 raw judgment까지 바로 연결되도록 설계했습니다.

README
서사

data
raw + csv

figures
발표/논문

present
ppt + notes

Phase 1-6 전체 실험 흐름

이 슬라이드의 목적: 발표 후반 결과를 이해할 수 있도록 phase별 역할을 미리 정렬한다.

P1	P2	P3	P4	P5	P6
Self-judge bias	예비 비교	메인 scaling	InternLM	GPT-4o-mini	330 split hold-out

- Phase 1-2: self-judge 편향과 예비 외부 judge sanity check
- Phase 3: 메인 same-family scaling 실험(Qwen 7B/14B/32B)
- Phase 4-5: InternLM20B, GPT-4o-mini로 cross-family / external check
- Phase 6: 11개 모델 풀에서 exhaustive leave-4-out hold-out

Phase 1-2: self-judge 편향과 예비 sanity check

이 슬라이드의 목적: 외부 judge가 왜 필요한지, 그리고 메인 실험 전 무엇을 확인했는지 보여준다.

- Qwen2.5-7B self-judge는 Math·Coding 점수를 과대 평가하는 편향이 나타남
- 외부 14B judge 도입 후 서열은 안정화되지만 pairwise inconsistency는 여전히 높음
- 즉 '오픈소스 judge를 쓰자'보다 '어떤 judge를 어떻게 쓰나'가 더 중요함

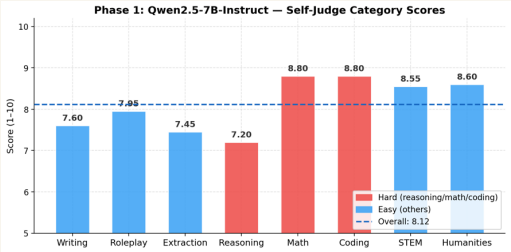

Phase 1: self-judge 결과

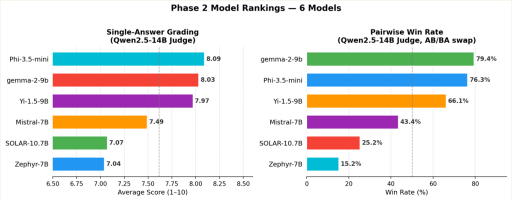

초기 전체 서열 확인

Phase 3: Qwen same-family scaling이 보여준 메인

이 슬라이드의 목적: Judge 크기 증가가 inconsistency를 어떻게 바꾸는지 메인 empirical trend를 각인시킨다.

- Pairwise inconsistency: 7B 78.75% → 14B 46.85% → 32B 32.86%
- 점수 범위도 0.84pt → 1.13pt → 1.47pt로 확대되어 변별력 증가
- 메인 claim은 `Qwen same-family empirical trend`로 제한해서 읽어야 함

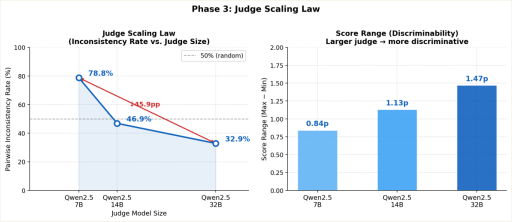

Judge scaling과 카테고리별 inconsistency

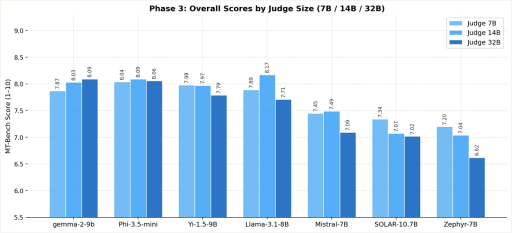

Phase 3 single-grade 점수 분포

Phase 3 심화: residual bias와 문항 변별도

이 슬라이드의 목적: 단순히 inconsistency가 줄었다는 사실을 넘어, 남는 오류의 성격까지 설명한다.

- 32B judge의 남은 불일치 중 94.9%가 first-position win으로 연결
- 즉 judge가 커질수록 '남는 오류'는 위치 편향 중심으로 농축됨
- 문항 변별도는 Math·Coding·Reasoning에서 특히 높아 tinyMT의 근거가 됨

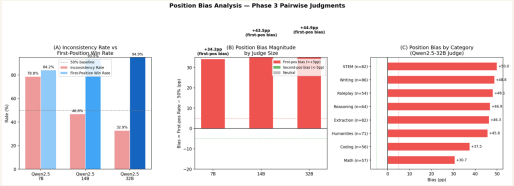

Residual position bias

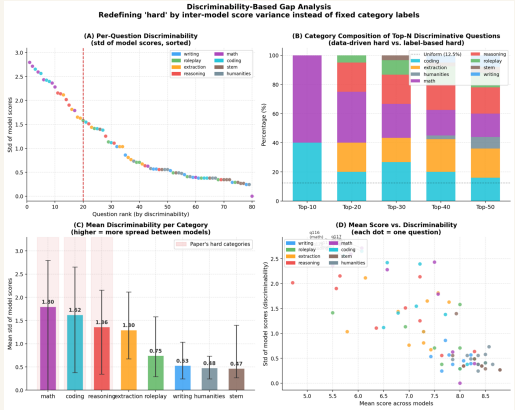

문항 변별도 분포

Phase 4: InternLM2.5는 무엇을 보여주고 무엇은 못

이 슬라이드의 목적: 보조 cross-family judge의 가치와 실패 사례를 동시에 보여줘 신뢰도를 높인다.

- InternLM2.5-20B는 Qwen32와 Spearman ρ=0.893로 broad ranking을 유지
- 반면 InternLM2.5-7B pairwise는 winner=error가 72.6%로 실전 judge로 부적합
- 즉 'cross-family check는 됨', 하지만 '아무 7B judge나 pairwise에 쓰면 안 됨'

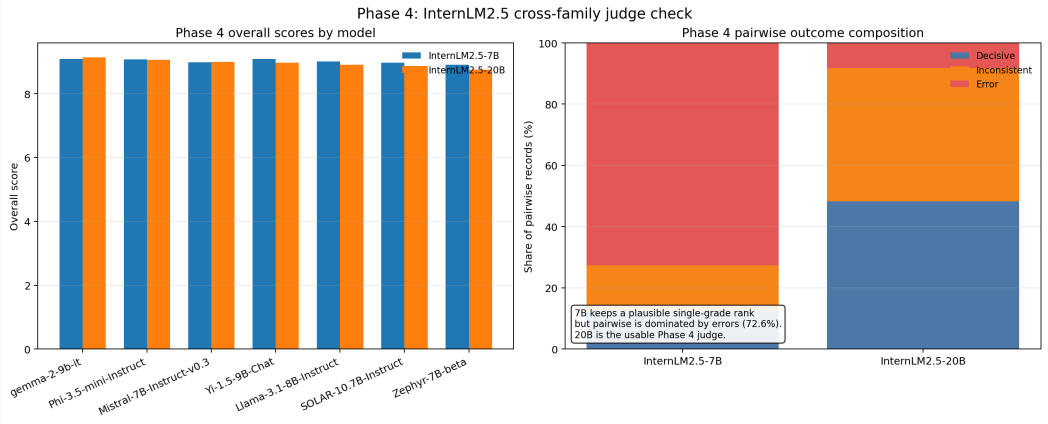

Phase 4: InternLM judge 결과

Phase 5: GPT-4o-mini는 외부 기준점으로 충분한가

이 슬라이드의 목적: closed API judge를 외부 기준점으로 썼을 때 메인 결과가 얼마나 유지되는지 보여준다.

- Qwen32 ↔ GPT-4o-mini: Spearman ρ=0.964, Kendall τ=0.905
- Pairwise inconsistency도 33.99%로 Qwen32의 32.86%와 매우 유사
- 즉 Qwen32 결과는 완전한 closed-source artifact는 아님

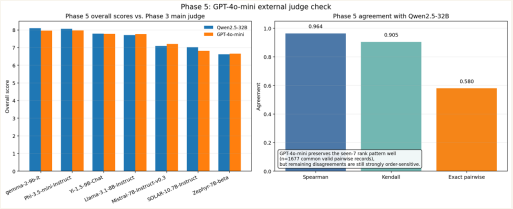

Phase 5: GPT-4o-mini 결과

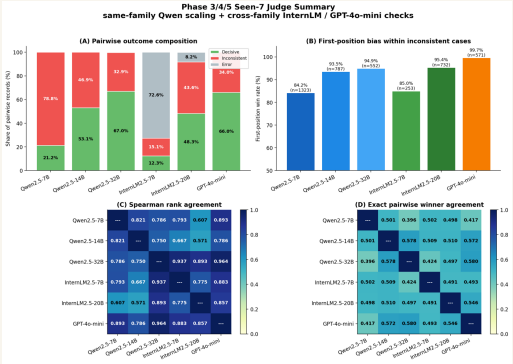

Phase 3/4/5 judge 요약

앙상블은 정말 큰 judge를 이길 수 있는가

이 슬라이드의 목적: 실무적으로 가장 궁금한 질문 하나에 대해 명확한 yes/no를 준다.

- 단순 다수결 앙상블은 오히려 단일 32B보다 나쁨: 58.63% > 32.86%
- inconsistent를 기권 처리한 abstain ensemble은 24.70%로 가장 낮음
- 핵심 교훈: 저품질 judge를 그냥 합치면 평균이 아니라 오염이 됨

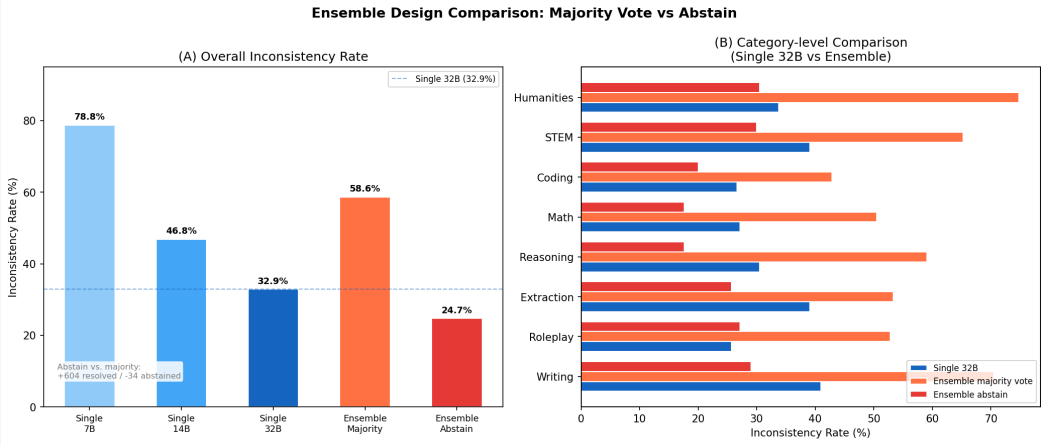

다수결 vs 기권 앙상블 비교

tinyMT-Bench same-set 결과: 왜 40문항이 강했는

이 슬라이드의 목적: 문항 축소 아이디어의 출발점과 same-set 상한을 명확히 설명한다.

- same-set 기준 Top-Disc-40은 ρ=1.000으로 full-80 ranking을 완전 보존
- Top-Disc-25도 ρ=0.964로 강하지만, 1개 순위 역전이 발생
- same-set에서는 40문항이 가장 설득력 있는 비용 절감 upper bound

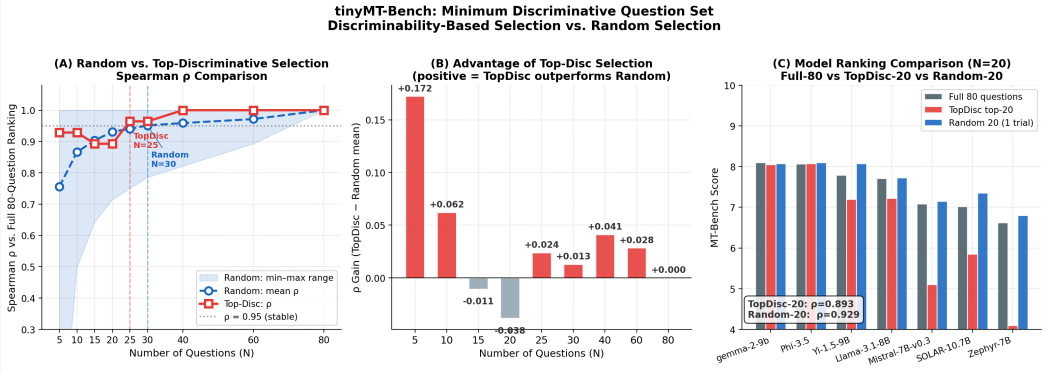

same-set tinyMT-Bench 결과

Repeated hold-out 결과: 40문항은 강하고, 60문항

이 슬라이드의 목적: Phase 6가 lucky draw가 아니라 반복 hold-out 결과라는 점을 데이터로 보여준다.

- 11개 모델에서 leave-4-out hold-out 330 split, 각 N마다 random 200개 비교
- Top-Disc-40 평균 ρ: Qwen 0.968 / InternLM20B 0.922 / GPT-4o-mini 0.959
- judge 공통으로 더 안전한 구간은 Top-Disc-60: 0.998 / 0.995 / 0.972

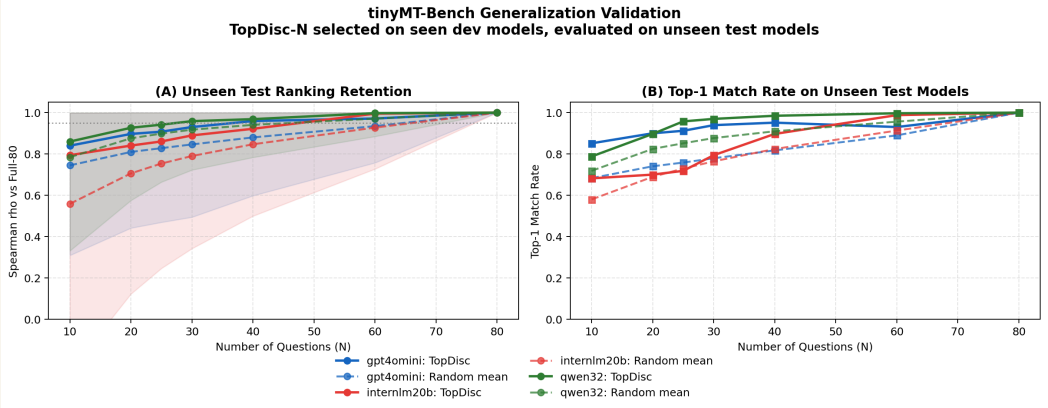

Repeated hold-out generalization 결과

그래서 이 연구에서 무엇을 믿고, 무엇은 아직 조심해야

이 슬라이드의 목적: 주장의 범위와 한계를 스스로 통제해 발표 전체 신뢰도를 끌어올린다.

- 믿을 수 있는 것: Qwen same-family scaling trend, cross-family broad rank stability, repeated hold-out의 60문항 권고
- 조심할 것: 11개 모델 풀은 7B-11B same-era chat 모델 중심
- 아직 열린 질문: 70B급, code-specialist, multilingual 환경까지도 같은가

좋은 발표는 강한 결과를 크게 말하고, 약한 결과를 정확히 말합니다.

same-fa
강함

cross-fa
보조 검증 완료

tinyMT
60문항 권고

남은 과제
cross-/multili!

최종 정리: 베이스 논문을 넘어, 오픈소스 judge를 실제

이 슬라이드의 목적: 20분 발표의 메시지를 세 문장으로 남기고 토론으로 넘긴다.

- 베이스 논문은 GPT-4 judge의 가능성을 열었고, 내 작업은 오픈소스 judge의 실전 신뢰도를 따졌다.
- 메인 결과는 `32B open-weight judge + abstain ensemble + 60문항 운영점`이다.
- Git 저장소는 논문 결과뿐 아니라 raw judgment, figure, deck까지 다시 생성 가능하게 정리했다.

질문 받겠습니다.

메인 실험	보조 검증	최신 점수	발표 포인
Phase 3	Phase 4-6	87/100 패키지	정직한 설정